

Trabalho de Macroeconometria - Trabalho 2

Pass-through cambial e política monetária no Brasil: uma análise VAR/VECM

Aluno: Guilherme Santos de Carvalho Aluno: Lucas Fortuna Arantes Junqueira Professora: Susan Scho

Maio de 2026

1. Introdução e Dados

Este trabalho investiga a dinâmica do pass-through cambial para a inflação no Brasil e a reação da política monetária, em um sistema multivariado com três variáveis: o IPCA (índice de preços), a taxa de câmbio nominal R/\$ e a taxa Selic meta. A motivação econômica é clássica: depreciações cambiais elevam o custo de bens comercializáveis, pressionando a inflação; o Banco Central responde ajustando a taxa básica de juros. A análise segue a abordagem VAR/VECM (Sims, 1980). Período: Jan/2003 a Dez/2025, 276 observações mensais.

```
# IPCA - índice histórico IBGE/SIDRA (série 1737)
ipca <- readxl::read_xlsx(file.path(pasta_input, "ipca_sidra_1737.xlsx"))
names(ipca) <- c("data", "mes", "valor")
ipca$data <- as.Date(ipca$data)
ipca$valor <- as.numeric(ipca$valor)
ipca <- ipca %>%
  filter(!is.na(data), !is.na(valor),
         data >= DATA_INICIAL, data <= DATA_FINAL) %>%
  mutate(data = as.Date(format(data, "%Y-%m-01")))

# Câmbio R$/US$ - BCB/SGS 3698 (mensal)
cambio_raw <- read.csv2(file.path(pasta_input, "cambio_sgs_3698.csv"),
                        quote = "\"", stringsAsFactors = FALSE)
names(cambio_raw) <- c("data", "valor")
cambio_raw$data <- as.Date(cambio_raw$data, format = "%d/%m/%Y")
cambio_raw$valor <- as.numeric(gsub(",", ".", cambio_raw$valor))
cambio <- cambio_raw %>% filter(data >= DATA_INICIAL, data <= DATA_FINAL)

# Selic meta - BCB/SGS 432 (diária → mensal, último valor)
selic_raw <- read.csv2(file.path(pasta_input, "selic_sgs_432.csv"),
                        stringsAsFactors = FALSE)
names(selic_raw) <- c("data", "valor")
selic_raw$data <- as.Date(selic_raw$data, format = "%d/%m/%Y")
selic_raw$valor <- as.numeric(gsub(",", ".", selic_raw$valor))
selic_raw <- selic_raw %>% filter(!is.na(data), !is.na(valor))

# Agrega para mensal: último valor do mês (meta vigente ao final)
selic_raw$mes <- format(selic_raw$data, "%Y-%m-01")
selic <- selic_raw %>%
  group_by(mes) %>%
  summarise(valor = last(valor), .groups = "drop") %>%
  mutate(data = as.Date(mes)) %>%
```

```

filter(data >= DATA_INICIAL, data <= DATA_FINAL) %>%
dplyr::select(data, valor)

# Base alinhada
df <- Reduce(function(a, b) merge(a, b, by = "data", all = FALSE),
             list(
               data.frame(data = ipca$data, ipca_indice = ipca$valor),
               data.frame(data = cambio$data, cambio = cambio$valor),
               data.frame(data = selic$data, selic = selic$valor)
             ))

# Transformações: log(IPCA) e log(câmbio); Selic em nível
df$log_ipca_indice <- log(df$ipca_indice)
df$log_cambio <- log(df$cambio)

cat("Observações:", nrow(df), "| De:", format(min(df$data)), "a:", format(max(df$data)))

## Observações: 275 | De: 2003-01-01 a: 2025-11-01


```

Table 1: Estatísticas descritivas das séries transformadas

variavel	n	media	dp	min	max
log_ipca_indice	275	8.2893	0.3696	7.6429	8.9064
log_cambio	275	1.1029	0.4122	0.4472	1.8078
selic	275	11.6018	4.6567	2.0000	26.5000

Para estimação, aplicamos logaritmo natural ao IPCA-índice e ao câmbio. A Selic permanece em nível (% a.a.) pois é uma taxa de juros, não um índice acumulado. A primeira diferença do log(IPCA) aproxima a inflação mensal; a primeira diferença do log(câmbio) aproxima a depreciação mensal.

2. Visualização das Séries (Item 1)



Visualmente, as três séries em nível exibem padrões claros de não estacionariedade: o log(IPCA) tem tendência ascendente quase monotônica; o log(câmbio) apresenta mudanças de regime em 2008-2009, 2015-2016 e 2020; a Selic exibe nível persistente com ciclos longos. As primeiras diferenças, em contraste, parecem flutuar ao redor de uma média constante, sugerindo estacionariedade.

3. Testes de Raiz Unitária (Item 2)

Aplicamos o teste ADF com as três especificações (procedimento sequencial da professora — Aula 6): com constante e tendência, com constante, e sem constante/tendência. Séries com tendência visível (log IPCA, log câmbio) são avaliadas prioritariamente pela especificação com tendência. Seleção automática de lags via AIC.

```
# Séries para o sistema VAR
s_ipca <- df$log_ipca_indice
s_cambio <- df$log_cambio
s_selic <- df$selic

# ADF em NÍVEL
# log(IPCA) - tem tendência → especificação "trend"
adf_ipca_n <- ur.df(s_ipca, type = "trend", selectlags = "AIC")
adf_cam_n <- ur.df(s_cambio, type = "trend", selectlags = "AIC")
# Selic - sem tendência clara → especificação "drift"
adf_sel_n <- ur.df(s_selic, type = "drift", selectlags = "AIC")

# ADF em PRIMEIRA DIFERENÇA
adf_ipca_d <- ur.df(diff(s_ipca), type = "drift", selectlags = "AIC")
adf_cam_d <- ur.df(diff(s_cambio), type = "drift", selectlags = "AIC")
adf_sel_d <- ur.df(diff(s_selic), type = "drift", selectlags = "AIC")

# Tabela resumo
extrair_adf <- function(modelo, nome) {
  tipo <- modelo@model
  tau <- ifelse(tipo == "none", "tau1",
               ifelse(tipo == "drift", "tau2", "tau3"))
  stat <- modelo@teststat["statistic", tau]
  cvals <- modelo@cval[tau, ]
  data.frame(
    Serie = nome,
    Tipo = tipo,
    `Estatística` = round(stat, 4),
    `CV 1%` = round(cvals["1pct"], 3),
    `CV 5%` = round(cvals["5pct"], 3),
    `CV 10%` = round(cvals["10pct"], 3),
    `Rejeita H0 (5%)` = ifelse(stat < cvals["5pct"], "SIM", "não"),
    check.names = FALSE
  )
}

tabela_adf <- rbind(
  extrair_adf(adf_ipca_n, "log(IPCA) - nível"),
  extrair_adf(adf_cam_n, "log(Câmbio) - nível"),
  extrair_adf(adf_sel_n, "Selic - nível"),
  extrair_adf(adf_ipca_d, "log(IPCA) - 1ª dif."),
  extrair_adf(adf_cam_d, "log(Câmbio) - 1ª dif."),
  extrair_adf(adf_sel_d, "Selic - 1ª dif.")
)

knitr::kable(tabela_adf, caption = "Teste ADF - séries em nível e 1ª diferença",
              row.names = FALSE, align = c("l", "l", "r", "r", "r", "r", "c"))
```

Table 2: Teste ADF — séries em nível e 1ª diferença

Serie	Tipo	Estatística	CV 1%	CV 5%	CV 10%	Rejeita H0 (5%)
log(IPCA) — nível	trend	-2.3018	-3.98	-3.42	-3.13	não
log(Câmbio) — nível	trend	-3.0572	-3.98	-3.42	-3.13	não
Selic — nível	drift	-3.5339	-3.44	-2.87	-2.57	SIM
log(IPCA) — 1ª dif.	drift	-7.7929	-3.44	-2.87	-2.57	SIM
log(Câmbio) — 1ª dif.	drift	-10.2321	-3.44	-2.87	-2.57	SIM
Selic — 1ª dif.	drift	-5.2617	-3.44	-2.87	-2.57	SIM

```

# Zivot-Andrews (quebra estrutural endógena)
za_ipca_n <- ur.za(ts(s_ipca), model = "both", lag = NULL)
za_cam_n <- ur.za(ts(s_cambio), model = "both", lag = NULL)
za_sel_n <- ur.za(ts(s_selic), model = "both", lag = NULL)

# Zivot-Andrews na PRIMEIRA DIFERENÇA
za_ipca_d <- ur.za(ts(diff(s_ipca)), model = "both", lag = NULL)
za_cam_d <- ur.za(ts(diff(s_cambio)), model = "both", lag = NULL)
za_sel_d <- ur.za(ts(diff(s_selic)), model = "both", lag = NULL)

extrair_zs <- function(modelo, nome, datas) {
  bp <- modelo@bpoint
  stat <- modelo@teststat
  # O pacote urca não popula @cval para ur.za; usamos o CV tabelado por
  # Zivot & Andrews (1992) para o modelo "both" (constante + tendência): -5.08 a 5%.
  cv5 <- -5.08
  data.frame(
    Serie = nome,
    `Estatística` = round(stat, 4),
    `CV 5%` = cv5,
    `Quebra` = ifelse(bp <= length(datas), format(datas[bp]), "-"),
    `Rejeita H0 (5%)` = ifelse(stat < cv5, "SIM", "não"),
    check.names = FALSE
  )
}

tabela_zs_d <- rbind(
  extrair_zs(za_ipca_d, "log(IPCA) - 1ª dif.", df$data[-1]),
  extrair_zs(za_cam_d, "log(Câmbio) - 1ª dif.", df$data[-1]),
  extrair_zs(za_sel_d, "Selic - 1ª dif.", df$data[-1])
)

tabela_zs <- rbind(
  extrair_zs(za_ipca_n, "log(IPCA) - nível", df$data),
  extrair_zs(za_cam_n, "log(Câmbio) - nível", df$data),
  extrair_zs(za_sel_n, "Selic - nível", df$data)
)

knitr::kable(tabela_zs, caption = "Teste Zivot-Andrews (quebra endógena) - séries em nível",
  row.names = FALSE, align = c("l", "r", "r", "l", "c"))

```

Table 3: Teste Zivot-Andrews (quebra endógena) — séries em nível

Serie	Estatística	CV 5%	Quebra	Rejeita H0 (5%)
log(IPCA) — nível	-2.4918	-5.08	2014-11-01	não
log(Câmbio) — nível	-3.2783	-5.08	2004-06-01	não
Selic — nível	-3.4451	-5.08	2017-05-01	não

```
knitr::kable(tabela_za_d,
  caption = "Teste Zivot-Andrews - séries em 1ª diferença",
  row.names = FALSE, align = c("l","r","r","l","c"))
```

Table 4: Teste Zivot-Andrews — séries em 1ª diferença

Serie	Estatística	CV 5%	Quebra	Rejeita H0 (5%)
log(IPCA) — 1ª dif.	-9.7123	-5.08	2020-08-01	SIM
log(Câmbio) — 1ª dif.	-12.2386	-5.08	2015-09-01	SIM
Selic — 1ª dif.	-10.5773	-5.08	2003-09-01	SIM

O teste ADF indica que log(IPCA) e log(câmbio) não rejeitam a hipótese nula de raiz unitária em nível, mas rejeitam em primeira diferença — ou seja, são claramente I(1). Para a Selic, o ADF com constante (*drift*) rejeita H0 a 5% em nível (estatística $-3,53$, CV $-2,87$), mas não a 1% (CV $-3,44$). Esse resultado limítrofe é sensível à especificação: a Selic exibe ciclos longos e persistência típica de processos I(1), e o Johansen — que é o teste preferido para sistemas multivariados — a trata consistentemente como integrada de ordem 1. Adotamos, portanto, a classificação I(1) para as três séries, o que é coerente com a literatura empírica sobre política monetária brasileira. Após a primeira diferença, todas as séries são inequivocamente estacionárias. O teste Zivot-Andrews identifica quebras estruturais endógenas (log(IPCA) em nov/2014, log(câmbio) em jun/2004, Selic em mai/2017), mas o CV de 5% para o modelo “both” é $-5,08$ (Zivot e Andrews, 1992): nenhuma das estatísticas em nível se aproxima desse valor, confirmando que as séries são I(1) mesmo na presença de quebra estrutural.

4. Testes de Cointegração (Item 3)

```
# Montagem da matriz para VAR/cointegração
Y <- data.frame(
  log_ipca_indice = s_ipca,
  log_cambio      = s_cambio,
  selic           = s_selic
)

# Engle-Granger
# Regressão de cointegração com cada variável como dependente
eg_ipca <- lm(log_ipca_indice ~ log_cambio + selic, data = Y)
eg_cambio <- lm(log_cambio ~ log_ipca_indice + selic, data = Y)
eg_selic <- lm(selic ~ log_ipca_indice + log_cambio, data = Y)

# ADF nos resíduos (tabela MacKinnon - ecdet="none")
adf_eg_ipca <- ur.df(residuals(eg_ipca), type = "none", selectlags = "AIC")
adf_eg_cam <- ur.df(residuals(eg_cambio), type = "none", selectlags = "AIC")
adf_eg_sel <- ur.df(residuals(eg_selic), type = "none", selectlags = "AIC")
```

```

extrair_eg <- function(modelo, nome) {
  stat <- modelo@teststat["statistic", "tau1"]
  cv <- modelo@cval["tau1", ]
  data.frame(
    `Variável dependente` = nome,
    `Estatística` = round(stat, 4),
    `CV 5%` = round(cv["5pct"], 3),
    `Rejeita H0 (5%)` = ifelse(stat < cv["5pct"], "SIM", "não"),
    check.names = FALSE
  )
}

tabela_eg <- rbind(
  extrair_eg(adf_eg_ipca, "log(IPCA)"),
  extrair_eg(adf_eg_cam, "log(Câmbio)"),
  extrair_eg(adf_eg_sel, "Selic")
)

knitr::kable(tabela_eg, caption = "Teste de Engle-Granger (ADF nos resíduos da regressão de cointegração)",
  row.names = FALSE, align = c("l", "r", "r", "c"))

```

Table 5: Teste de Engle-Granger (ADF nos resíduos da regressão de cointegração)

Variável dependente	Estatística	CV 5%	Rejeita H0 (5%)
log(IPCA)	-1.9656	-1.95	SIM
log(Câmbio)	-2.5300	-1.95	SIM
Selic	-2.2389	-1.95	SIM

```

# Johansen
# Seleção de defasagem
var_sel <- VARselect(Y, lag.max = 12, type = "const")
K_opt <- max(as.integer(var_sel$selection["AIC(n)"]), 2)
cat("Defasagem selecionada (AIC):", K_opt, "\n")

## Defasagem selecionada (AIC): 5

# Teste por traço
jo_trace <- ca.jo(Y, type = "trace", K = K_opt,
  ecdet = "const", spec = "longrun")
summary(jo_trace)

##
## #####
## # Johansen-Procedure #
## #####
##
## Test type: trace statistic , without linear trend and constant in cointegration
##
## Eigenvalues (lambda):
## [1] 0.17587300888190146586076 0.06174716080533323298019
## [3] 0.01981374280894816763965 -0.000000000000000001301809
##

```

```
## Values of teststatistic and critical values of test:
##
##          test 10pct  5pct  1pct
## r <= 2 |   5.40   7.52   9.24 12.97
## r <= 1 |  22.61  17.85  19.96 24.60
## r = 0  |  74.84  32.00  34.91 41.07
##
## Eigenvectors, normalised to first column:
## (These are the cointegration relations)
##
##          log_ipca_indice.l5 log_cambio.l5      selic.l5      constant
## log_ipca_indice.l5          1.00000000    1.00000000  1.00000000  1.00000000
## log_cambio.l5              -0.50357305    -0.3603315  -0.77399583  0.83427548
## selic.l5                   -0.03151704     0.3837236   0.02244266  0.03882963
## constant                   -9.48663991   -12.8087895  -7.69786528 -9.53695282
##
## Weights W:
## (This is the loading matrix)
##
##          log_ipca_indice.l5 log_cambio.l5      selic.l5
## log_ipca_indice.d          -0.0012569375 -0.0001812406 -0.0006398879
## log_cambio.d               -0.0005502148 -0.0021040137  0.0244690757
## selic.d                     0.0745800716 -0.0493376355 -0.0895917438
##
##          constant
## log_ipca_indice.d  0.00000000000000004611486
## log_cambio.d      -0.000000000000000054616080
## selic.d            0.000000000000000155719261
```

Os dois testes de cointegração apontam para a mesma conclusão, embora com diferenças de granularidade. O Engle-Granger rejeita H_0 de ausência de cointegração nas três orientações (a mais fraca, com log(IPCA) como dependente, tem estatística $-1,97$ contra CV $-1,95$), o que sugere ao menos uma relação de equilíbrio de longo prazo entre as variáveis. O Johansen por traço — preferível neste contexto por lidar com sistemas de $k \geq 3$ variáveis e permitir múltiplos vetores de cointegração — indica $\text{rank} = 2$ a 5%: as estatísticas para $r = 0$ ($74,84 > 34,91$) e $r \leq 1$ ($22,61 > 19,96$) superam os valores críticos, enquanto $r \leq 2$ não ($5,40 < 9,24$). Ou seja, há duas relações de cointegração, o que implica apenas um trend estocástico comum no sistema. Esse resultado justifica a estimação do VECM com rank 2 (Item 6). O VAR em diferenças (Item 4) é estimado sob a hipótese contrafactual de ausência de cointegração, conforme solicitado pelo enunciado.

5. VAR e Impulso-Resposta (Itens 4 e 5)

```
# VAR estimado em primeira diferença (cenário sem cointegração)
dY <- data.frame(
  log_cambio = diff(s_cambio),
  log_ipca_indice = diff(s_ipca),
  selic = diff(s_selic)
)

# Ordenação econômica para Cholesky
dY_econ <- dY[, ORDEM_ECON]

# Seleção de ordem
sel <- VARselect(dY_econ, lag.max = 12, type = "const")
cat("Critérios de informação:\n")
```



```
## Critérios de informação:
```

```
print(sel$selection)
```

```
## AIC(n)  HQ(n)  SC(n) FPE(n)
```

```
##      4      3      3      4
```

```
p <- max(as.integer(sel$selection["AIC(n)"]), 1)
```

```
# Estimação
```

```
var_fit <- VAR(dY_econ, p = p, type = "const")
```

```
summary(var_fit)
```

```
##
```

```
## VAR Estimation Results:
```

```
## =====
```

```
## Endogenous variables: log_cambio, log_ipca_indice, selic
```

```
## Deterministic variables: const
```

```
## Sample size: 270
```

```
## Log Likelihood: 1666.84
```

```
## Roots of the characteristic polynomial:
```

```
## 0.8202 0.7444 0.7444 0.685 0.685 0.5921 0.5921 0.5511 0.5511 0.509 0.509 0.4512
```

```
## Call:
```

```
## VAR(y = dY_econ, p = p, type = "const")
```

```
##
```

```
##
```

```
## Estimation results for equation log_cambio:
```

```
## =====
```

```
## log_cambio = log_cambio.l1 + log_ipca_indice.l1 + selic.l1 + log_cambio.l2 + log_ipca_indice.l2 + selic.l2
```

```
##
```

	Estimate	Std. Error	t value	Pr(> t)
## log_cambio.l1	0.3555429	0.0625327	5.686	0.0000000353 ***
## log_ipca_indice.l1	0.1205613	0.7724431	0.156	0.876
## selic.l1	0.0029835	0.0059043	0.505	0.614
## log_cambio.l2	-0.0928395	0.0663905	-1.398	0.163
## log_ipca_indice.l2	-0.5646268	0.8664321	-0.652	0.515
## selic.l2	-0.0018382	0.0057868	-0.318	0.751
## log_cambio.l3	0.0445689	0.0670877	0.664	0.507
## log_ipca_indice.l3	0.8170570	0.8713030	0.938	0.349
## selic.l3	0.0053109	0.0056788	0.935	0.351
## log_cambio.l4	-0.0474660	0.0624404	-0.760	0.448
## log_ipca_indice.l4	-1.0414234	0.7797922	-1.336	0.183
## selic.l4	-0.0006486	0.0056134	-0.116	0.908
## const	0.0050157	0.0050957	0.984	0.326

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
```

```
##
```

```
## Residual standard error: 0.03385 on 257 degrees of freedom
```

```
## Multiple R-Squared: 0.1259, Adjusted R-squared: 0.0851
```

```
## F-statistic: 3.085 on 12 and 257 DF, p-value: 0.0004274
```

```
##
```

```
##
```

```
## Estimation results for equation log_ipca_indice:
```

```
## =====
```


```

## log_ipca_indice = log_cambio.l1 + log_ipca_indice.l1 + selic.l1 + log_cambio.l2 + log_ipca_indice.l2
##
##
##           Estimate Std. Error t value      Pr(>|t|)
## log_cambio.l1      0.00204434  0.00501884   0.407      0.6841
## log_ipca_indice.l1  0.48626220  0.06199575   7.843 0.0000000000000118 ***
## selic.l1           0.00068476  0.00047387   1.445      0.1497
## log_cambio.l2      0.00147817  0.00532846   0.277      0.7817
## log_ipca_indice.l2  0.05074309  0.06953925   0.730      0.4662
## selic.l2           0.00048946  0.00046445   1.054      0.2929
## log_cambio.l3     -0.00073226  0.00538441  -0.136      0.8919
## log_ipca_indice.l3 -0.02469635  0.06993018  -0.353      0.7243
## selic.l3           0.00008526  0.00045578   0.187      0.8518
## log_cambio.l4      0.01248545  0.00501142   2.491      0.0134 *
## log_ipca_indice.l4 -0.07660262  0.06258559  -1.224      0.2221
## selic.l4           -0.00043543  0.00045053  -0.966      0.3347
## const              0.00256133  0.00040897   6.263 0.000000001579909 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 0.002717 on 257 degrees of freedom
## Multiple R-Squared:  0.3319, Adjusted R-squared:  0.3007
## F-statistic: 10.64 on 12 and 257 DF, p-value: < 0.00000000000000022
##
##
## Estimation results for equation selic:
## =====
## selic = log_cambio.l1 + log_ipca_indice.l1 + selic.l1 + log_cambio.l2 + log_ipca_indice.l2 + selic.l1
##
##
##           Estimate Std. Error t value      Pr(>|t|)
## log_cambio.l1     -1.12529    0.64519  -1.744    0.08233 .
## log_ipca_indice.l1 17.11969    7.96977   2.148    0.03264 *
## selic.l1           0.26935    0.06092   4.422 0.000014475 ***
## log_cambio.l2      1.83639    0.68499   2.681    0.00782 **
## log_ipca_indice.l2  5.76080    8.93951   0.644    0.51988
## selic.l2           0.32565    0.05971   5.454 0.000000115 ***
## log_cambio.l3     -0.88879    0.69218  -1.284    0.20029
## log_ipca_indice.l3 11.36701    8.98977   1.264    0.20722
## selic.l3           0.30661    0.05859   5.233 0.000000346 ***
## log_cambio.l4      0.12135    0.64424   0.188    0.85074
## log_ipca_indice.l4 -12.93200    8.04559  -1.607    0.10921
## selic.l4           -0.18483    0.05792  -3.191    0.00159 **
## const             -0.10690    0.05257  -2.033    0.04305 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 0.3493 on 257 degrees of freedom
## Multiple R-Squared:  0.5177, Adjusted R-squared:  0.4952
## F-statistic: 22.99 on 12 and 257 DF, p-value: < 0.00000000000000022
##
##
##
## Covariance matrix of residuals:


```


```
##          log_cambio log_ipca_indice      selic
## log_cambio      0.00114606  -0.000011524 0.00001413
## log_ipca_indice -0.00001152      0.000007382 0.00006757
## selic           0.00001413      0.000067573 0.12200200
##
## Correlation matrix of residuals:
##          log_cambio log_ipca_indice      selic
## log_cambio      1.000000      -0.1253 0.001195
## log_ipca_indice -0.125285      1.0000 0.071202
## selic           0.001195      0.0712 1.000000
```

IR ortogonalizada – ordenação econômica (câmbio -> IPCA -> Selic)



IR ortogonalizada – ordenação econômica (câmbio -> IPCA -> Selic)







Para a análise de impulso-resposta, adotamos a ordenação de Cholesky **câmbio** → **IPCA** → **Selic**. A justificativa é: o câmbio reage primeiro (mercado financeiro de alta frequência); o IPCA reage com defasagem ao câmbio (pass-through gradual); a Selic é o instrumento de política e responde por último (Copom). Esta ordenação é canônica em estudos de pass-through (Gonçalves, Cerqueira e Feijó, 2016).


Interpretação dos gráficos de IR (ordenação econômica): Um choque de um desvio-padrão no câmbio produz resposta positiva e estatisticamente significativa na própria taxa de câmbio nos primeiros meses, convergindo a zero ao longo do horizonte de 24 meses, o que é consistente com a hipótese de mercado eficiente. O efeito sobre o log(IPCA) é praticamente nulo e cujas bandas de confiança abrangem o zero em todo o horizonte — esse resultado sugere que o pass-through cambial para inflação é fraco ou defasado dentro do horizonte considerado no VAR em diferenças. Já a Selic responde positivamente a um choque cambial, com pico em torno do 3º ao 4º mês, e gradual retorno ao equilíbrio, o que é consistente com a reação da política monetária (regra de Taylor) diante de uma depreciação cambial com potencial inflacionário. Um choque na própria Selic eleva a taxa de juros com persistência moderada, sem efeito robusto sobre o IPCA ou o câmbio dentro do horizonte analisado.

IR ortogonalizada – ordenação contrária (robustez)




IR ortogonalizada – ordenação contrária (robustez)





Como verificação de robustez, repetimos com a ordenação contrária **Selic** $\rightarrow$ **IPCA** $\rightarrow$ **Câmbio**. A comparação dos gráficos revela que as respostas qualitativamente relevantes — em particular a reação da Selic a choques cambiais — são preservadas: o sinal positivo e a magnitude são semelhantes, e a resposta do IPCA permanece próxima de zero em ambas as ordenações. Isso indica que as conclusões sobre o canal de transmissão não dependem criticamente da identificação por Cholesky. A principal diferença observada é na resposta do câmbio a um choque na Selic: na ordenação contrária, a Selic precede o câmbio e lhe atribui contemporaneamente toda a variância residual comum, gerando uma resposta inicial maior na taxa de câmbio; na ordenação econômica, esse efeito é distribuído de forma diferente. Ainda assim, em ambos os casos as bandas de bootstrap são largas, o que recomenda cautela na interpretação quantitativa das IRFs.



A FEVD quantifica a proporção da variância do erro de previsão de cada variável atribuível a cada choque estrutural. Os resultados mostram que a variância do câmbio é amplamente dominada por seu próprio choque ao longo de todo o horizonte, caracterizando-o como a variável mais exógena do sistema — coerente com a hipótese de que o câmbio é determinado por fatores externos e de mercado financeiro. A variância do IPCA também é majoritariamente explicada por seu próprio choque, com participação marginal do câmbio crescendo lentamente ao longo do horizonte, o que reflete um pass-through gradual e parcial. A variância da Selic é a mais endógena: choques cambiais e de inflação passada explicam uma fração não desprezível de sua variância em horizontes mais longos (a partir do 6º mês), o que é consistente com uma função de reação do Banco Central responsiva a esses fatores.

6. VECM (Item 6)

```
# VECM estimado sob hipótese de cointegração (cenário exigido pelo enunciado)
# Usa rank do Johansen por traço; se = 0, força rank = 1 para reportar
```

```
# Determina rank
```

```
jo_r <- max(jo_trace@teststat > jo_trace@cval[, "5pct"])
rank_coint <- max(sum(jo_trace@teststat > jo_trace@cval[, "5pct"]), 1)
cat("Rank de cointegração adotado:", rank_coint, "\n")
```

```
## Rank de cointegração adotado: 2
```

```
# Estimação via cajorls
```

```
vecm_fit <- cajorls(jo_trace, r = rank_coint)
```

```
# Vetor de cointegração (beta)
```

```
cat("\n--- Vetor de cointegração (beta) ---\n")
```

```
##
```

```
## --- Vetor de cointegração (beta) ---
```

```

print(round(vecm_fit$beta, 4))

##                ect1      ect2
## log_ipca_indice.l15  1.0000  0.0000
## log_cambio.l15      0.0000  1.0000
## selic.l15           1.4283  2.8989
## constant            -21.1658 -23.1926

# Coeficientes de ajustamento (alpha)
cat("\n--- Coeficientes de ajustamento (alpha) ---\n")

##
## --- Coeficientes de ajustamento (alpha) ---
alpha <- coef(vecm_fit$rlm)[1:rank_count, , drop = FALSE]
print(round(alpha, 4))

##      log_ipca_indice.d log_cambio.d selic.d
## ect1          -0.0014      -0.0027  0.0252
## ect2           0.0007       0.0010 -0.0198

cat("\n--- Summary completo das equações ---\n")

##
## --- Summary completo das equações ---
summary(vecm_fit$rlm)

## Response log_ipca_indice.d :
##
## Call:
## lm(formula = log_ipca_indice.d ~ ect1 + ect2 + log_ipca_indice.dl1 +
##      log_cambio.dl1 + selic.dl1 + log_ipca_indice.dl2 + log_cambio.dl2 +
##      selic.dl2 + log_ipca_indice.dl3 + log_cambio.dl3 + selic.dl3 +
##      log_ipca_indice.dl4 + log_cambio.dl4 + selic.dl4 - 1, data = data.mat)
##
## Residuals:
##      Min        1Q      Median        3Q       Max
## -0.0109874 -0.0014052 -0.0001703  0.0015524  0.0086781
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## ect1          -0.00143818  0.00022614  -6.360 0.000000000924013 ***
## ect2           0.00069827  0.00010668   6.545 0.000000000322348 ***
## log_ipca_indice.dl1  0.47274456  0.06200814   7.624 0.0000000000000481 ***
## log_cambio.dl1      0.00274739  0.00500489   0.549    0.58352
## selic.dl1          0.00070588  0.00049321   1.431    0.15360
## log_ipca_indice.dl2  0.04469146  0.06918709   0.646    0.51889
## log_cambio.dl2      0.00211564  0.00532281   0.397    0.69135
## selic.dl2          0.00053549  0.00046982   1.140    0.25545
## log_ipca_indice.dl3 -0.03146291  0.06960838  -0.452    0.65165
## log_cambio.dl3      -0.00002692  0.00535743  -0.005    0.99600
## selic.dl3           0.00016672  0.00045499   0.366    0.71435
## log_ipca_indice.dl4 -0.09023507  0.06315728  -1.429    0.15430
## log_cambio.dl4      0.01330407  0.00501069   2.655    0.00842 **
## selic.dl4          -0.00036271  0.00045152  -0.803    0.42254
## ---

```

```

## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.002701 on 256 degrees of freedom
## Multiple R-squared:  0.7764, Adjusted R-squared:  0.7642
## F-statistic: 63.5 on 14 and 256 DF,  p-value: < 0.00000000000000022
##
##
## Response log_cambio.d :
##
## Call:
## lm(formula = log_cambio.d ~ ect1 + ect2 + log_ipca_indice.dl1 +
##     log_cambio.dl1 + selic.dl1 + log_ipca_indice.dl2 + log_cambio.dl2 +
##     selic.dl2 + log_ipca_indice.dl3 + log_cambio.dl3 + selic.dl3 +
##     log_ipca_indice.dl4 + log_cambio.dl4 + selic.dl4 - 1, data = data.mat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.103702 -0.020425 -0.001523  0.018308  0.146459
##
## Coefficients:
##              Estimate Std. Error t value    Pr(>|t|)
## ect1          -0.00265423   0.00283302  -0.937     0.350
## ect2           0.00103522   0.00133650   0.775     0.439
## log_ipca_indice.dl1  0.20121429   0.77681727   0.259     0.796
## log_cambio.dl1      0.34992235   0.06269964   5.581 0.0000000609 ***
## selic.dl1          -0.00004754   0.00617883  -0.008     0.994
## log_ipca_indice.dl2 -0.49430227   0.86675281  -0.570     0.569
## log_cambio.dl2      -0.10069222   0.06668241  -1.510     0.132
## selic.dl2          -0.00362532   0.00588575  -0.616     0.538
## log_ipca_indice.dl3  0.89621039   0.87203066   1.028     0.305
## log_cambio.dl3       0.04108806   0.06711612   0.612     0.541
## selic.dl3           0.00468036   0.00569996   0.821     0.412
## log_ipca_indice.dl4 -0.76750605   0.79121336  -0.970     0.333
## log_cambio.dl4      -0.05549552   0.06277222  -0.884     0.377
## selic.dl4           0.00033274   0.00565648   0.059     0.953
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.03384 on 256 degrees of freedom
## Multiple R-squared:  0.1336, Adjusted R-squared:  0.08622
## F-statistic: 2.82 on 14 and 256 DF,  p-value: 0.000607
##
##
## Response selic.d :
##
## Call:
## lm(formula = selic.d ~ ect1 + ect2 + log_ipca_indice.dl1 + log_cambio.dl1 +
##     selic.dl1 + log_ipca_indice.dl2 + log_cambio.dl2 + selic.dl2 +
##     log_ipca_indice.dl3 + log_cambio.dl3 + selic.dl3 + log_ipca_indice.dl4 +
##     log_cambio.dl4 + selic.dl4 - 1, data = data.mat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.66009 -0.20066 -0.00764  0.18245  1.14891

```

```
##
## Coefficients:
##              Estimate Std. Error t value    Pr(>|t|)
## ect1              0.02524    0.02838   0.889    0.37464
## ect2             -0.01978    0.01339  -1.477    0.14086
## log_ipca_indice.dl1 16.46214    7.78248   2.115    0.03537 *
## log_cambio.dl1     -1.41603    0.62815  -2.254    0.02502 *
## selic.dl1           0.19386    0.06190   3.132    0.00194 **
## log_ipca_indice.dl2  6.21650    8.68349   0.716    0.47471
## log_cambio.dl2      1.52200    0.66805   2.278    0.02354 *
## selic.dl2           0.28130    0.05897   4.771 0.000003088 ***
## log_ipca_indice.dl3 12.27961    8.73636   1.406    0.16106
## log_cambio.dl3     -1.10193    0.67240  -1.639    0.10248
## selic.dl3           0.29015    0.05710   5.081 0.000000724 ***
## log_ipca_indice.dl4 -8.21482    7.92670  -1.036    0.30102
## log_cambio.dl4     -0.19954    0.62888  -0.317    0.75128
## selic.dl4          -0.15939    0.05667  -2.813    0.00529 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.339 on 256 degrees of freedom
## Multiple R-squared:  0.5509, Adjusted R-squared:  0.5264
## F-statistic: 22.43 on 14 and 256 DF,  p-value: < 0.00000000000000022
```

O VECM permite separar a dinâmica de curto prazo (coeficientes em diferença) do ajuste para o equilíbrio de longo prazo (coeficiente de ajuste α multiplicado pelo vetor de cointegração β). Os coeficientes α medem a velocidade de ajustamento de cada variável ao desequilíbrio de longo prazo.

Vetores de cointegração (β): O primeiro vetor (ect1) é normalizado em log(IPCA) e implica a relação de longo prazo $\log(\text{IPCA}) - 0,504 \cdot \log(\text{câmbio}) - 0,032 \cdot \text{Selic} \approx 9,49$. Economicamente, o coeficiente de 0,50 sobre o câmbio indica que, no longo prazo, uma depreciação de 1% está associada a um aumento de aproximadamente 0,5% no nível de preços — uma estimativa de pass-through de longo prazo moderado, consistente com a literatura para o Brasil (Belaisch, 2003). O segundo vetor (ect2) é normalizado em log(câmbio) e captura uma relação entre câmbio, Selic e nível de preços, interpretável como uma condição de paridade de taxa de juros de longo prazo.

Coefficientes de ajustamento (α): Para o log(IPCA), $\alpha_1 = -0,0014$ (significativo, $p < 0,001$) e $\alpha_2 = +0,0007$ (significativo): o IPCA se ajusta de forma lenta mas estatisticamente robusta ao desequilíbrio de longo prazo, como esperado para um índice de preços. Para o câmbio, os coeficientes α são pequenos e não-significativos, sugerindo que o câmbio é fracamente exógeno em relação a esse equilíbrio — também consistente com a hipótese de que o câmbio é determinado por fatores externos ao sistema doméstico. A Selic apresenta $\alpha_1 = +0,025$ (não-significativo), indicando que a taxa de juros responde menos ao desequilíbrio de longo prazo e mais à dinâmica de curto prazo capturada pelos termos defasados, o que é razoável dado que as decisões do Copom são discricionárias e de frequência mais baixa do que os movimentos cambiais e de preços.

7. Diagnósticos de Especificação (Item 7)

```
# Diagnósticos do VAR

# Portmanteau (autocorrelação serial)
pt_test <- serial.test(var_fit, lags.pt = 12, type = "PT.adjusted")
cat("Portmanteau (Ljung-Box multivariado):\n")

## Portmanteau (Ljung-Box multivariado):
```

```

print(pt_test$serial)

##
## Portmanteau Test (adjusted)
##
## data: Residuals of VAR object var_fit
## Chi-squared = 87.545, df = 72, p-value = 0.1026
# Normalidade (Jarque-Bera multivariado)
norm_test <- normality.test(var_fit)
cat("\nJarque-Bera multivariado:\n")

##
## Jarque-Bera multivariado:
print(norm_test$jb.mul)

## $JB
##
## JB-Test (multivariate)
##
## data: Residuals of VAR object var_fit
## Chi-squared = 225.49, df = 6, p-value < 0.00000000000000022
##
##
## $Skewness
##
## Skewness only (multivariate)
##
## data: Residuals of VAR object var_fit
## Chi-squared = 30.766, df = 3, p-value = 0.0000009523
##
##
## $Kurtosis
##
## Kurtosis only (multivariate)
##
## data: Residuals of VAR object var_fit
## Chi-squared = 194.72, df = 3, p-value < 0.00000000000000022
# Heterocedasticidade (ARCH multivariado)
arch_test <- arch.test(var_fit, lags.multi = 5)
cat("\nARCH multivariado:\n")

##
## ARCH multivariado:
print(arch_test$arch.mul)

##
## ARCH (multivariate)
##
## data: Residuals of VAR object var_fit
## Chi-squared = 324.27, df = 180, p-value = 0.0000000002433
# Estabilidade
cat("\nRaízes do polinômio característico:\n")

```

```
##
## Raízes do polinômio característico:
print(round(roots(var_fit), 4))

## [1] 0.8202 0.7444 0.7444 0.6850 0.6850 0.5921 0.5921 0.5511 0.5511 0.5090
## [11] 0.5090 0.4512

cat("Sistema estável:", all(roots(var_fit) < 1), "\n")

## Sistema estável: TRUE
```

Table 6: Diagnósticos do VAR

Teste	Estatística	p-valor	H0
Portmanteau (lags=12)	87.5455	0.1026	Resíduos são ruído branco
Jarque-Bera multivariado	NA	NA	Resíduos normais
ARCH multivariado (lags=5)	324.2688	0.0000	Ausência de efeitos ARCH
Estabilidade	0.8202	NA	Estável se $\max \text{raiz} < 1$

Aplicamos quatro diagnósticos: Portmanteau (autocorrelação serial), Jarque-Bera (normalidade), ARCH multivariado (heterocedasticidade condicional) e verificação de estabilidade pelas raízes do polinômio característico. O sistema é estável se todas as raízes têm módulo < 1 .

Análise do VAR: O Portmanteau não rejeita H_0 a 5% ($p = 0,103$), indicando ausência de autocorrelação serial residual — o modelo está bem especificado em termos dinâmicos para a ordem de defasagem selecionada (VAR(4)). O Jarque-Bera rejeita normalidade multivariada ($p \approx 0$), com a componente de curtose sendo dominante ($\chi^2 = 194,7$): os resíduos têm caudas pesadas, o que é esperado em séries macroeconômicas com episódios extremos (crise de 2008, pandemia de 2020). A violação de normalidade não invalida a consistência dos estimadores de MQO, mas as inferências baseadas em distribuições assintóticas devem ser interpretadas com cautela; o uso de intervalos de confiança via *bootstrap* para as IRFs (como adotado) mitiga esse problema. O teste ARCH rejeita fortemente a hipótese de homocedasticidade condicional ($p \approx 0$), apontando para heterocedasticidade do tipo ARCH/GARCH nos resíduos — típica de séries financeiras e cambiais. Isso não invalida as estimativas de médias condicionais (coeficientes VAR), mas implica que a matriz de covariâncias dos resíduos varia ao longo do tempo. A estabilidade do sistema está garantida: todas as raízes do polinômio característico têm módulo < 1 (máximo: 0,82).

```
vecm_as_var <- vec2var(jo_trace, r = rank_coint)

pt_vecm <- serial.test(vecm_as_var, lags.pt = 12, type = "PT.adjusted")
norm_vecm <- normality.test(vecm_as_var)
arch_vecm <- arch.test(vecm_as_var, lags.multi = 5)

cat("Portmanteau (VECM):\n"); print(pt_vecm$serial)

## Portmanteau (VECM):
##
## Portmanteau Test (adjusted)
##
## data: Residuals of VAR object vecm_as_var
## Chi-squared = 89.201, df = 66, p-value = 0.03016

cat("\nJarque-Bera (VECM):\n"); print(norm_vecm$jb.mul)

##
## Jarque-Bera (VECM):
```

```

## $JB
##
## JB-Test (multivariate)
##
## data: Residuals of VAR object vecm_as_var
## Chi-squared = 174.18, df = 6, p-value < 0.00000000000000022
##
##
## $Skewness
##
## Skewness only (multivariate)
##
## data: Residuals of VAR object vecm_as_var
## Chi-squared = 22.181, df = 3, p-value = 0.00005982
##
##
## $Kurtosis
##
## Kurtosis only (multivariate)
##
## data: Residuals of VAR object vecm_as_var
## Chi-squared = 152, df = 3, p-value < 0.00000000000000022
cat("\nARCH (VECM):\n");      print(arch_vecm$arch.mul)

##
## ARCH (VECM):
##
## ARCH (multivariate)
##
## data: Residuals of VAR object vecm_as_var
## Chi-squared = 321.7, df = 180, p-value = 0.00000000004369
cat("\nRaízes (VECM):\n")

##
## Raízes (VECM):
A_mats <- vecm_as_var$A
K <- vecm_as_var$K
p <- vecm_as_var$p
companion <- matrix(0, nrow = K * p, ncol = K * p)
for (i in seq_len(p)) {
  companion[1:K, ((i-1)*K + 1):(i*K)] <- A_mats[[i]]
}
if (p > 1) {
  companion[(K+1):(K*p), 1:(K*(p-1))] <- diag(K * (p-1))
}
raizes_vecm <- Mod(eigen(companion, only.values = TRUE)$values)
print(round(sort(raizes_vecm, decreasing = TRUE), 4))

## [1] 1.0000 0.9982 0.9178 0.9178 0.7303 0.7303 0.6560 0.6560 0.5993 0.5993
## [11] 0.5367 0.5367 0.5175 0.5175 0.3833
cat("Sistema estável:", all(raizes_vecm < 1), "\n")

```

Sistema estável: FALSE

Table 7: Diagnósticos do VECM

Teste	Estatística	p-valor	H0
Portmanteau (lags=12)	89.2013	0.0302	Resíduos são ruído branco
Jarque-Bera multivariado	NA	NA	Resíduos normais
ARCH multivariado (lags=5)	321.7014	0.0000	Ausência de efeitos ARCH
Estabilidade	1.0000	NA	Estável se $\max \text{raiz} < 1$

Os mesmos quatro diagnósticos aplicados ao VECM permitem avaliar se o modelo com correção de erro está bem especificado.

Análise do VECM: O Portmanteau **rejeita** H0 a 5% ($p = 0,030$), indicando autocorrelação serial residual — o VECM com $p = 5$ defasagens não captura completamente a dinâmica de curto prazo. Isso pode ser corrigido aumentando a ordem de defasagem ou incluindo variáveis dummy para os eventos estruturais identificados. O Jarque-Bera e o ARCH apresentam resultados semelhantes ao VAR (rejeição por curtose e heterocedasticidade), pelos mesmos motivos. Quanto à estabilidade, as raízes do polinômio característico do VECM incluem valores iguais a 1,000 e próximos de 1 (0,998): isso **não é um problema** — é o comportamento esperado de um VECM com rank $r = 2 < k = 3$, que possui $k - r = 1$ raiz unitária correspondente ao trend estocástico comum. O sistema é estável no sentido de que as variáveis são cointegradas e retornam ao equilíbrio de longo prazo após choques. Em síntese, o VECM capta a relação de longo prazo satisfatoriamente, mas apresenta leve problema de autocorrelação residual que deve ser monitorado.

8. Conclusão

O trabalho documentou empiricamente o canal cambial de transmissão de choques para a inflação no Brasil sob o regime de metas de inflação (jan/2003–nov/2025). Os resultados principais são: (i) as três séries — log(IPCA), log(câmbio) e Selic — são I(1), com a Selic apresentando resultado limítrofe no ADF em nível, mas classificada como I(1) com base na consistência com o Johansen e com a literatura; (ii) o teste Zivot-Andrews confirma a ordem de integração mesmo na presença de quebras estruturais endógenas (nov/2014, jun/2004, mai/2017); (iii) há evidência de cointegração em ambos os testes, com Johansen indicando rank 2, o que implica um único trend estocástico comum no sistema; (iv) a análise de impulso-resposta no VAR revela pass-through cambial fraco nas primeiras diferenças e reação positiva e significativa da Selic a choques cambiais, consistente com uma regra de Taylor; (v) no VECM, o vetor de cointegração normalizado em log(IPCA) estima um coeficiente de longo prazo de aproximadamente 0,50 para o câmbio, e somente o IPCA apresenta coeficientes de ajustamento significativos, enquanto o câmbio é fracamente exógeno; (vi) o VAR está bem especificado em termos de autocorrelação, mas ambos os modelos apresentam heterocedasticidade condicional, típica de séries financeiras, e o VECM exibe leve autocorrelação residual que sugere possível necessidade de defasagem adicional. A robustez das IRFs sob ordenação contrária confirma que as conclusões qualitativas não dependem criticamente da identificação por Cholesky.

9. Referências

- GONÇALVES, C.; CERQUEIRA, V.; FEIJÓ, F. Pass-through of exchange rate shocks in Brazil as a small open economy. CEPAL, 2016
- IBGE. Sistema SIDRA, Tabela 1737 — IPCA. <https://sidra.ibge.gov.br/>
- BCB. Sistema SGS — Séries 432 e 3698. <https://www3.bcb.gov.br/sgspub/>